

Análise da Correlação entre os Preços do Petróleo e a Atratividade de Investimentos em Geração Solar e Eólica

Lucas S. Ribeiro e Maria E. Ribeiro dos Passos

Resumo: A interdependência entre a volatilidade dos preços do petróleo bruto (Brent) e o fluxo de investimentos em fontes renováveis (solar e eólica) no Brasil constitui o objeto central desta investigação. Compreendendo o intervalo entre 2012 e 2026, o trabalho utiliza o ecossistema SQL para processos de ETL e a biblioteca Scikit-Learn para aplicar modelagem preditiva via algoritmo *Random Forest*. O objetivo central é identificar a sensibilidade macroeconômica das fontes renováveis e o impacto indireto na dinâmica de custos e despacho em cenários de oscilação dos combustíveis fósseis. Os resultados comprovam uma assimetria estrutural na transição energética: enquanto a geração solar apresenta forte dependência e sensibilidade em relação ao Brent (16,92%), funcionando como um mecanismo de proteção tarifária de curto prazo, a expansão eólica demonstra alta resiliência aos choques do petróleo (3,46%), vinculando-se a ciclos estruturais de longo prazo. Ambas as previsões consolidam a geração hídrica como o lastro de controle operativo essencial do sistema.

Palavras-Chave: *Feature Importance*, Mercado de Energia, Petróleo Brent, *Random Forest*, Transição Energética.

I. Introdução

A transição para uma economia de baixo carbono evidencia a forte influência das flutuações do petróleo (Brent) nos investimentos em energias renováveis [5]. No Brasil, essa dinâmica culmina no "Paradoxo da Transição Energética": embora o barril em alta favoreça teoricamente as fontes limpas – ao encarecer a energia fóssil e elevar o Custo Marginal de Operação (CMO) [5] –, ele também desencadeia pressões inflacionárias e o consequente aumento das taxas básicas de juros [4]. Como projetos eólicos e solares exigem alto dispêndio de capital inicial (CAPEX), os juros elevados aumentam o Custo Nivelado de Energia (LCOE), desestimulando novos empreendimentos [4].

Como modelos de regressão tradicionais frequentemente falham em capturar as interações não-lineares deste complexo cenário no Sistema Interligado Nacional (SIN), abordagens analíticas mais avançadas fazem-se necessárias. Portanto, o objetivo deste artigo é quantificar a assimetria de sensibilidade entre a volatilidade do Brent e a atratividade de investimentos solares e eólicos no Brasil.

Utilizando modelagem preditiva baseada em Inteligência Artificial (Random Forest), o estudo isola o impacto que os choques fósseis e o despacho hidrelétrico exercem sobre a expansão (em MWmed) dessas fontes. Com isso, busca-se fornecer insights quantitativos robustos para a tomada de decisão, mitigação de riscos e formulação de estratégias no Ambiente de Contratação Livre (ACL) e na Geração Distribuída (GD).

O trabalho está estruturado da seguinte forma: a Seção II apresenta os fundamentos do mercado de energia brasileiro; a Seção III detalha a engenharia de dados (ETL) e a arquitetura de Machine Learning; a Seção IV consolida os resultados quantitativos por meio de um dashboard interativo; e a Seção V apresenta as conclusões.

II. Fundamentos do Mercado de Energia

A. O Petróleo e o Paradoxo Macroeconômico da Transição

O índice Brent referencia o mercado energético global e impacta o Custo Marginal de Operação (CMO) através do acionamento termelétrico. Contudo, a relação entre o óleo e as fontes limpas é regida pelo "Paradoxo da Transição Energética". Embora o barril elevado aumente a competitividade teórica das renováveis frente aos fósseis, ele gera pressões inflacionárias na cadeia produtiva global. Para conter a inflação, as autoridades monetárias elevam a taxa básica de juros (Selic), encarecendo o custo do crédito. Esse mecanismo de transmissão atinge diretamente a viabilidade de novos parques limpos, que dependem massivamente de alavancagem financeira.

B. A Dinâmica de Custos (CAPEX, OPEX e LCOE)

A estrutura de capital das fontes renováveis inverte o modelo térmico tradicional, caracterizado por baixo custo de instalação e alto custo de combustível (alto OPEX). Em contrapartida, as gerações solar e eólica exigem um investimento inicial massivo (alto CAPEX), operando com custo marginal nulo. Para parametrizar viabilidades tão distintas, utiliza-se o Custo Nivelado de Energia (LCOE), que reflete o valor presente líquido do custo unitário da

eletricidade na vida útil do ativo. Sendo o LCOE altamente sensível ao Custo Médio Ponderado de Capital (WACC), cenários de juros altos elevam essa métrica e penalizam a atratividade e o fluxo de caixa dos novos empreendimentos.

C. O Sistema Interligado Nacional (SIN) e o Despacho Centralizado

No cenário brasileiro, a análise de investimentos integra-se à arquitetura de dimensões continentais do Sistema Interligado Nacional (SIN), operado centralizadamente pelo Operador Nacional do Sistema (ONS). O diferencial do SIN reside em sua base hidráulica e no regime de despacho otimizado. Face à intermitência climática das fontes eólica e solar, o ONS utiliza os grandes reservatórios hidrelétricos como uma "bateria física": a geração hídrica é retida nos momentos de excedente renovável e acionada na ausência de sol ou vento, garantindo a resiliência e a estabilidade operativa do sistema.

III. Metodologia e Engenharia de Dados

A pesquisa adota uma abordagem quantitativa e exploratória sobre uma série histórica que compreende o período de 2012 a 2026. Para garantir a fidelidade das informações, os dados foram extraídos de fontes oficiais: o histórico diário e mensal de geração de energia (Eólica, Solar e Hidrelétrica) foi coletado das bases do Operador Nacional do Sistema (ONS) e da Câmara de Comercialização de Energia Elétrica (CCEE) [7], [8], enquanto o histórico de cotações do petróleo bruto (Brent) foi extraído do IPEADATA [9].

A. Pipeline de Processamento e ETL (SQL):

Devido à disparidade de granularidade temporal e origem das fontes — dados operacionais de despacho do ONS/CCEE em base contínua versus cotações do petróleo no IPEADATA com fechamentos de mercado —, desenvolveu-se um *pipeline* de tratamento de dados estruturado em duas etapas complementares:

- **Camada de Integração e Armazenamento (SQL):** Realizou-se o processo de ETL (Extract, Transform, Load) primário via ambiente relacional SQL. Nesta fase, os dados brutos de geração e macroeconomia foram limpos, padronizados para a unidade de Megawatt médio (MWmed) e consolidados por meio de junções relacionais (JOINS) utilizando a data (Data) como chave primária.
- **Camada de Sanitização de Séries Temporais (Python/Pandas):** Para corrigir a descontinuidade do índice Brent aos finais de semana e feriados sem truncar o histórico de geração renovável, o dataset unificado foi importado para o ecossistema Python. Aplicou-se uma reamostragem temporal diária estrita (`asfreq('D')`). Em seguida, neutralizou-se a ausência de cotações financeiras nos dias não úteis através da imputação por inércia econômica via Forward Fill (`ffill`). Para as variáveis físicas e contínuas de geração (Solar, Eólica, Hídrica e Térmica), aplicou-se a interpolação linear entre os limites operacionais adjacentes, garantindo a integridade do balanço energético do SIN e zerando a presença de dados nulos (NaN) na matriz preditiva.

IV. Modelagem Preditiva: Random Forest

Para quantificar os canais de transmissão de volatilidade e superar as limitações de modelos lineares frente à complexidade do SIN, adotou-se o algoritmo *Random Forest* [11], implementado em Python via Scikit-Learn.

A. Estrutura do Algoritmo

Sendo um método de aprendizado supervisionado baseado na construção de múltiplas árvores de decisão, o modelo realiza partições sucessivas para mapear relações não-lineares. Foram desenvolvidos dois alvos preditivos independentes: geração Solar e Eólica. O algoritmo mapeou autonomamente como o preço do Brent e a geração hídrica afetam os despachos renováveis. Para mitigar *overfitting* e garantir acurácia, o *dataset* foi dividido em 80% para treinamento e 20% para teste.

B. Extração de Relevância (Feature Importance)

A escolha do *Random Forest* justifica-se pela sua capacidade nativa de calcular o *Feature Importance* (Importância das Variáveis). O modelo quantifica percentualmente o peso exato de cada variável independente (Brent, Geração Hídrica e Sazonalidade) sobre as fontes renováveis. Foi através desta métrica que a assimetria do investimento e os reflexos nas variações do LCOE puderam ser estatisticamente validados.

C. Visualização Analítica e Business Intelligence (Power BI)

Para consolidar os resultados e traduzir os modelos matemáticos em *insights* executivos, desenvolveu-se um *dashboard*

interativo no Microsoft Power BI [12]. Após a etapa de ETL e parametrização no Power Query, o painel atuou como *Front-End* analítico. A arquitetura visual integrou os resultados de *Feature Importance*, contrastando a assimetria macroeconômica entre as fontes. Além disso, a aplicação de KPIs e análises temporais evidenciou a função estabilizadora da base hídrica frente à intermitência, permitindo a simulação dinâmica de choques históricos de preços.

V. Visualização e Discussão dos Resultados

A consolidação via *Business Intelligence* e a extração estatística via *Machine Learning* permitiram validar matematicamente o comportamento do capital frente à expansão física da matriz elétrica.

A. A Evolução da Matriz e a Segurança Operativa do SIN

A análise temporal (2012 a 2026) evidencia dinâmicas distintas de atração de capital. Conforme ilustrado na **Fig. 1**, a geração eólica consolidou um crescimento linear e robusto a partir de 2015. Esse fenômeno baseia-se na estruturação via *Project Finance* para usinas *Utility-Scale*. Por dependerem de leilões no Ambiente de Contratação Regulada (ACR) e de longos PPAs (15 a 20 anos) no Ambiente de Contratação Livre (ACL), esses projetos adquirem uma inércia de crescimento isolada de choques econômicos pontuais.




Fig 1: Evolução histórica pareada da geração Eólica e Solar (2012-2026).

Em contraste, a fonte solar registra uma inflexão exponencial no biênio 2022-2023. O gatilho para essa alocação massiva de capital explica-se pelo despacho estocástico do ONS (modelos NEWAVE e DECOMP). Em ciclos de escassez hidrológica, a segurança do SIN exige o acionamento termelétrico, dinâmica evidenciada na **Fig. 2**. Este despacho atrela o Custo Marginal de Operação (CMO) às *commodities* fósseis, contaminando as tarifas com repasses inflacionários.




Figura 2: Gráfico de dispersão evidenciando a correlação operativa de segurança entre o despacho Hídrico e Térmico no SIN.

B. A Prova Matemática: Extração de Feature Importance

Para testar a hipótese de que a rápida

expansão solar atua como *hedge* (proteção) contra a inflação fóssil, utilizou-se a métrica de *Feature Importance* do *Random Forest*, calculada através da diminuição da impureza de Gini em cada nó de decisão. A **Fig. 3** consolida os resultados quantitativos, revelando uma forte assimetria estrutural na transição energética brasileira.

Fonte	Impacto na Solar	Impacto na Eólica
Geração Par	56,37%	81,21%
Brent	17,62%	3,16%
Hidrelétrica	14,91%	13,11%
Térmica	11,1%	2,52%

Figura 3: Importância relativa das variáveis (Feature Importance) calculada pelo modelo Random Forest.

No modelo eólico, o índice Brent apresentou uma relevância marginal de apenas 3,16%, comprovando a resiliência atrelada aos contratos de longo prazo, imunes à volatilidade mensal que afeta os fundos de *Private Equity*.

Por outro lado, o modelo preditivo atribuiu ao Brent um peso de 17,62% na expansão solar. Esta correlação não-linear reflete a dinâmica da Geração Distribuída (GD): o encarecimento do petróleo aciona térmicas e eleva as tarifas reguladas, reduzindo drasticamente o *Payback* de sistemas fotovoltaicos. Conclui-se, matematicamente, que o capital migra para a fonte solar como um mecanismo defensivo atrelado aos choques do mercado internacional de óleo.

VI. Análise de Cenários de Estresse Macroeconômico (2015, 2020 E 2025)

Para atestar a robustez explicativa do modelo, a série temporal foi submetida a um *backtesting*, isolando três anos caracterizados por anomalias macroeconômicas extremas. Essa segmentação metodológica atua como um teste de estresse focado nas premissas de investimento em infraestruturas de capital intensivo.

A. 2015: O Choque Hidrológico e Regulatório de 2015

O ano de 2015 representou um marco no SIN devido a uma seca histórica que levou os reservatórios do Sudeste/Centro-Oeste a níveis críticos. Para evitar o racionamento físico, o ONS forçou o despacho termelétrico fora da ordem de mérito, acionando usinas de altíssimo Custo Variável Unitário (CVU), como as térmicas a óleo diesel. A consequência direta foi a explosão do Preço de Liquidação das Diferenças (PLD) e a vigência contínua da Bandeira Tarifária Vermelha.

Neste ambiente de inflação de custos (*cost-push inflation*) e de avanços da Resolução Normativa nº 482 da ANEEL, o modelo preditivo captura o gatilho embrionário da geração solar. Conforme ilustra a **Fig. 4**, *early adopters* iniciaram a adoção da tecnologia fotovoltaica como instrumento de *hedge* para travar custos de longo prazo, mitigando a severa exposição ao LCOE fóssil que dominava o sistema.




Figura 4: Comportamento da geração Térmica e

ascensão incipiente da fonte Solar durante o choque hidrológico de 2015.

B. 2020: O Colapso do Petróleo e a Inelasticidade Renovável

Em 2020, a pandemia de COVID-19 provocou um choque deflacionário global, com *lockdowns* industriais causando massiva destruição de demanda e o colapso histórico do barril de Brent. No mercado elétrico brasileiro, a carga sistêmica retraiu fortemente, fornecendo um cenário ideal para testar a resiliência das diferentes matrizes de geração.

Conforme ilustrado na **Fig. 5**, o modelo comprova que, enquanto a energia térmica reduziu seu despacho acompanhando a retração da demanda e a queda do preço fóssil, a curva de geração das fontes eólica e solar manteve-se inelástica.




Figura 5: Absorção do choque deflacionário externo pelo SIN e o colapso do preço do Brent em 2020.

Neste período, a geração eólica chegou a registrar recordes de fator de capacidade no Nordeste (a "safra dos ventos"). Esse comportamento atesta a eficácia dos contratos *take-or-pay* estabelecidos no mercado, que garantem a remuneração das usinas independentemente da retração no consumo macroeconômico. O cenário de 2020 valida matematicamente a premissa de que a infraestrutura renovável possui resiliência estrutural para suportar choques agudos de contração econômica.

C. 2025: Geopolítica, Selic e a Corrida

do Marco Legal

O ano de 2025 encapsula um "Novo Normal" de alta complexidade para a infraestrutura. Externamente, conflitos geopolíticos e restrições da OPEP+ estabeleceram um piso elevado e volátil para o Brent. Internamente, a inflação persistente forçou a manutenção da taxa Selic em patamares restritivos.

No financiamento renovável, juros altos penalizam severamente o *Weighted Average Cost of Capital* (WACC), elevando o LCOE de novos parques eólicos e dificultando o fechamento de novos PPAs. Contudo, a geração solar apresentou um crescimento atípico. A iminência da cobrança pelo uso da rede ("Fio B"), determinada pela Lei 14.300/2022 (Marco Legal da Micro e Minigeração Distribuída), gerou uma corrida contra o tempo.

Conforme capturado pelo modelo na **Fig. 6**, investidores massificaram a injeção de capital para protocolar projetos e garantir o direito adquirido às regras anteriores.




Figura 6: Consolidação do mercado de Geração Distribuída e atração massiva de capital fotovoltaico em 2025.

Esta assíntota de crescimento na base instalada comprova que o capital nacional priorizou a energia fotovoltaica distribuída como um porto seguro contra a inflação fóssil e as altas tarifas, mesmo operando em um cenário de crédito extremamente encarecido.

VII. Conclusão

O estudo quantificou com êxito a interdependência entre a volatilidade do Brent e a atração de investimentos renováveis no Brasil. Ao transcender as limitações de modelos econométricos tradicionais, o algoritmo *Random Forest* decodificou matematicamente a assimetria comportamental do capital no Sistema Interligado Nacional (SIN).

A principal contribuição científica desta pesquisa reside na validação empírica do "Paradoxo da Transição Energética" por meio da métrica de *Feature Importance*. O modelo comprovou que a matriz reage de forma dicotômica aos choques externos: a geração eólica atestou resiliência estrutural, com sensibilidade marginal de apenas 3,16% ao Brent. Este comportamento inelástico decorre da estruturação via *Project Finance* e longos PPAs, que blindam os projetos contra a volatilidade fóssil.

Em contrapartida, a expansão solar exibiu aguda dependência da dinâmica do óleo (peso decisório de 17,62%). Esse resultado quantifica a tese da Geração Distribuída (GD): a escalada do barril força o ONS a despachar térmicas, elevando o Custo Marginal de Operação (CMO) e acionando as Bandeiras Tarifárias. A injeção de capital em sistemas fotovoltaicos atua, portanto,

como um *hedge* (proteção financeira) imediato da sociedade contra a inflação energética.

Ademais, o *backtesting* macroeconômico (2015, 2020 e 2025) confirmou o despacho hídrico como o lastro físico fundamental (amortecedor sistêmico) que viabiliza a expansão eólica e solar, cobrindo as intermitências de vento e radiação.

Por fim, as descobertas estabelecem um alicerce quantitativo para o setor de comercialização. Para trabalhos futuros, recomenda-se aplicar esta arquitetura preditiva na precificação de derivativos de energia, previsão avançada do Preço de Liquidação das Diferenças (PLD) e antecipação do LCOE frente a choques conjugados na Selic. Tal integração de Inteligência Artificial configura-se como indispensável para a gestão de riscos no Ambiente de Contratação Livre (ACL), uma fronteira analítica indispensável para a gestão de risco de portfólio e para a tomada de decisão em mesas de operações no Ambiente de Contratação Livre (ACL).

VIII. Referências

- [1] F. Pedregosa et al., "Scikit-learn: Machine Learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825-2830, 2011.
- [2] J. M. Wooldridge, *Introductory Econometrics: A Modern Approach*, 7th ed. Cengage Learning, 2019.
- [3] A. Silberschatz, H. F. Korth, and S. Sudarshan, *Database System Concepts*, 7th ed. McGraw-Hill, 2019.
- [4] IRENA, *Renewable Power Generation Costs in 2023*. International Renewable Energy Agency, Abu Dhabi, 2024.

- [5] IEA, *World Energy Outlook 2024*. International Energy Agency, Paris, 2024.
- [6] D. C. Montgomery, E. A. Peck, and G. G. Vining, *Introduction to Linear Regression Analysis*, 5th ed. Wiley, 2012.
- [7] ONS, "Portal de Dados Abertos do ONS," Operador Nacional do Sistema Elétrico, Brasília, Brasil, 2026. [Online]. Available: <https://dados.ons.org.br>
- [8] CCEE, "Dados e Indicadores da Câmara de Comercialização," Câmara de Comercialização de Energia Elétrica, São Paulo, Brasil, 2026. [Online]. Available: <https://www.ccee.org.br>
- [9] IPEA, "Ipeadata: Série Histórica de Cotação do Petróleo Bruto (Brent)," Instituto de Pesquisa Econômica Aplicada, Rio de Janeiro, Brasil, 2026. [Online]. Available: <http://www.ipeadata.gov.br>
- [10] BRASIL. "Lei nº 14.300, de 6 de janeiro de 2022. Institui o marco legal da microgeração e minigeração distribuída," Diário Oficial da União, Brasília, DF, 7 jan. 2022.
- [11] L. Breiman, "Random Forests," *Machine Learning*, vol. 45, no. 1, pp. 5-32, out. 2001.
- [12] Microsoft, "Documentação Oficial do Microsoft Power BI," Microsoft Corporation, 2026. [Online]. Available: <https://learn.microsoft.com/pt-br/power-bi/>